

# AI+X 인재양성 확대를 위한 교수자 연수

한국폴리텍대학 대구캠퍼스  
SI엔지니어링학과 강현우

# 3강

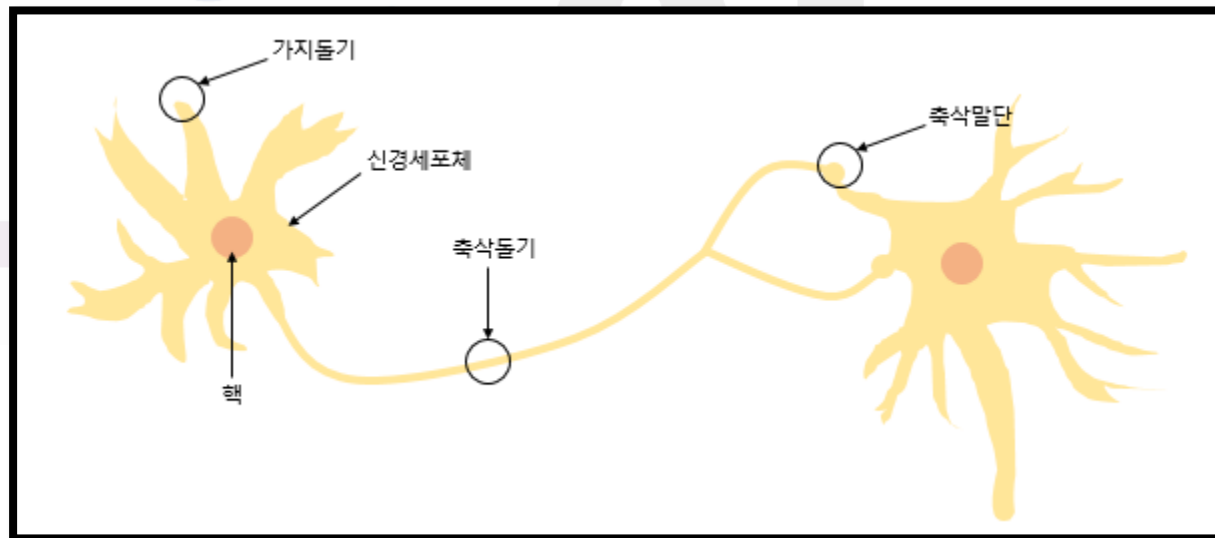
## -신경망 및 딥러닝 개요



# Overview

## ◆ 신경망



- 인간이 뇌를 통해 문제를 처리하는 방법과 비슷한 방법으로 컴퓨터에서 문제를 해결하려는 모델
- 뉴런
  - ✓ 가지돌기에서 신호를 받음
  - ✓ 신호가 일정치 이상이면 축삭 돌기로 신호를 전달



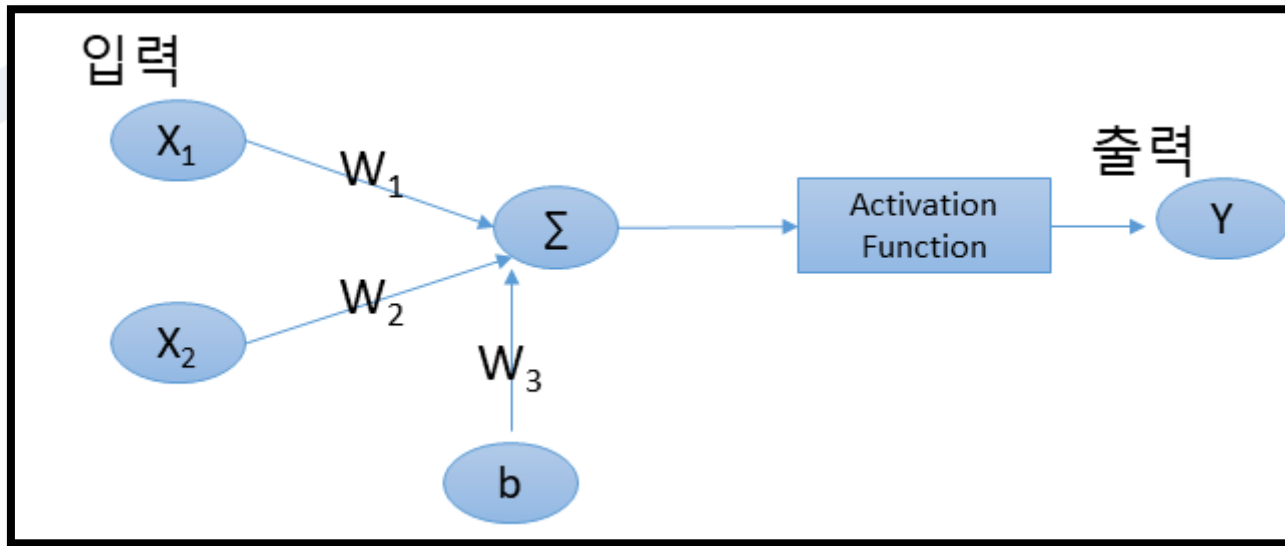
# Overview

## ◆ Activation Function (활성화 함수)

- 뉴런에 가해지는 신호가 특정 임계치 까지는
- 아무런 신호를 보내지 않다가 임계치를 초과하면
- 신호를 내보내는 것을 모방



# Perceptron 모델



활성화 함수  $y = f(\sum W_i X_i)$

$$\text{가중합} = W_0 X_0 + W_1 X_1 + W_3 b$$

# Neural Network

## ◆ 신경망

- 뉴런들을 여러 개 연결한 네트워크

## ◆ 신경망 학습

- 데이터를 통해  $W$ 의 값을 찾아내겠다

## ◆ 모델

- $W$  값들을 다 저장해둔게 모델이지 뭐.

# Weight 학습

## ◆ 어떤 입력에 대하여

- 원하는 출력값(목표값)  $d$  와
- 모델의 출력  $y$  사이에 차이가 발생
- 현재의 weight에 차이를 더해서 weight를 갱신

## ◆ weight를 갱신할 때 차이를 얼마나 줘?

- 그게 바로 **학습률**
- 학습률이 너무 높으면 최적의 결과를 얻지 못함
- 너무 낮으면 학습 시간이 오래 걸림

$$W_{n+1} = W_n + \eta(d - y)$$

# And 게이트 학습

학습데이터

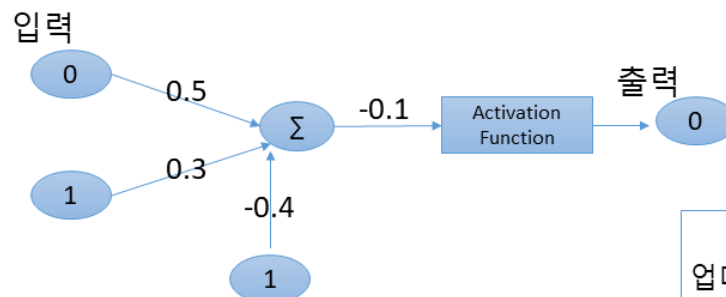
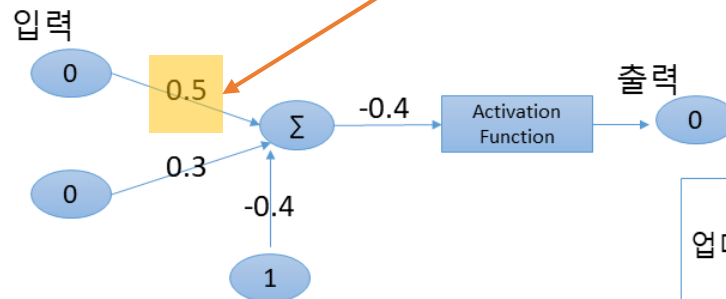
| x1 | x2 | d |
|----|----|---|
| 0  | 0  | 0 |
| 0  | 1  | 0 |
| 1  | 0  | 0 |
| 1  | 1  | 1 |

Activation Function

$$f(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

학습율 5% (0.05)

Weight의 초기값?  
-1 ~ 1 사이 랜덤





1라운드



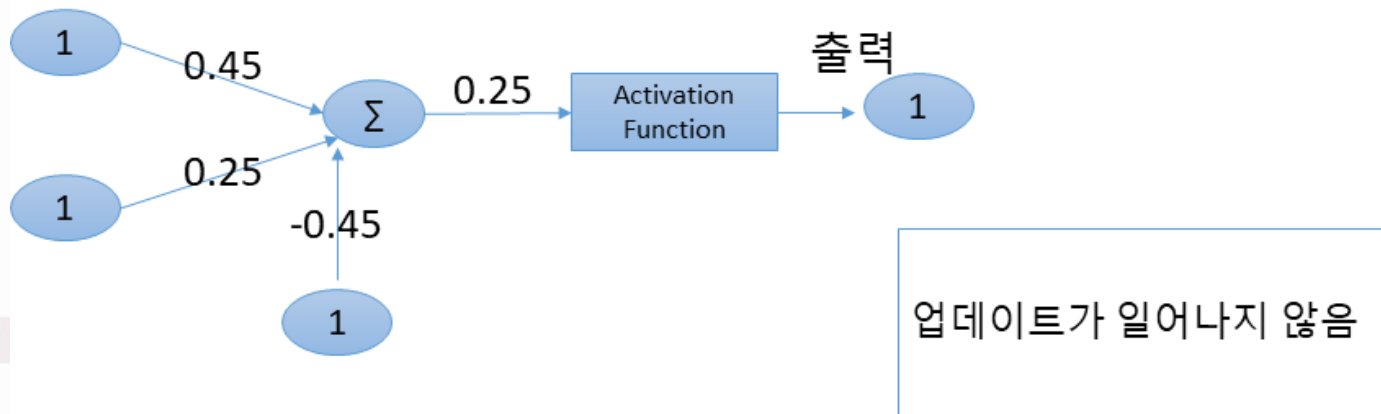

# Random

## ◆ Normal Distribution / Uniform Distribution

➤ 확률 밀도 함수 (Probability Density Function)



# And 게이트 학습



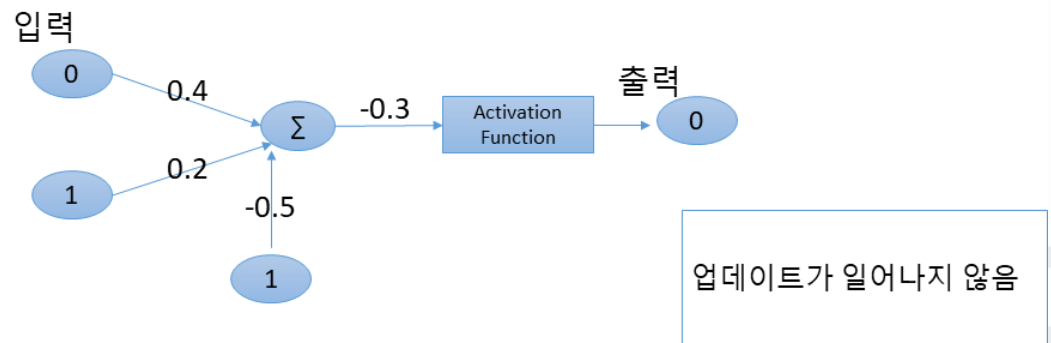
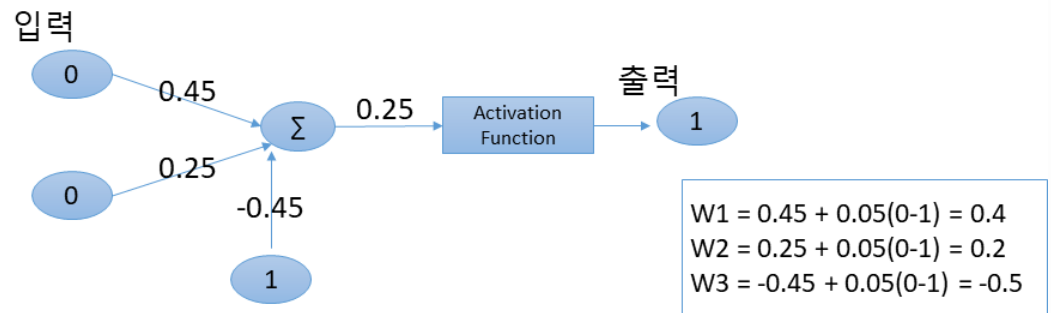
1라운드

라운드? = 모든 학습데이터를 1회 학습하면 1라운드  
Epoch 라는 표현으로 많이 사용함

# And 게이트 학습


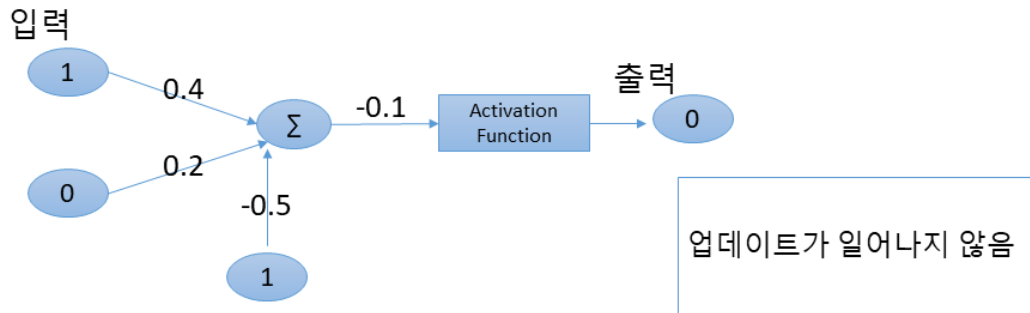
| x1 | x2 | d | y |
|----|----|---|---|
| 0  | 0  | 0 | 0 |
| 0  | 1  | 0 | 0 |
| 1  | 0  | 0 | 1 |
| 1  | 1  | 1 | 1 |

1라운드 종료 후 출력값  
정답률 = 75%



2라운드

# And 게이트 학습

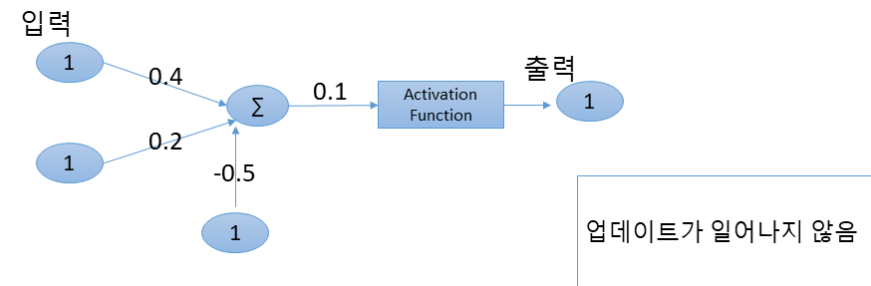
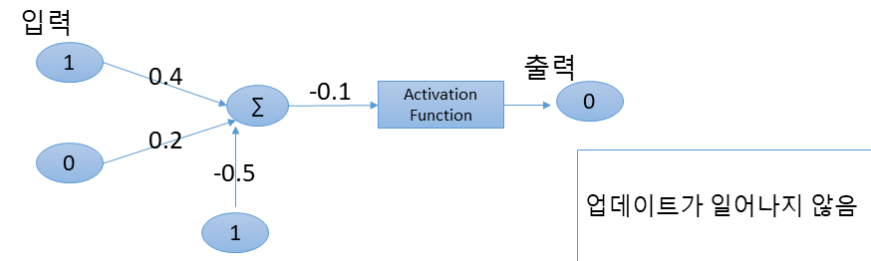
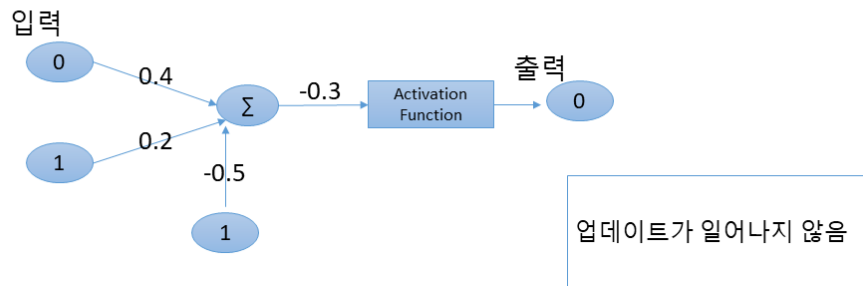
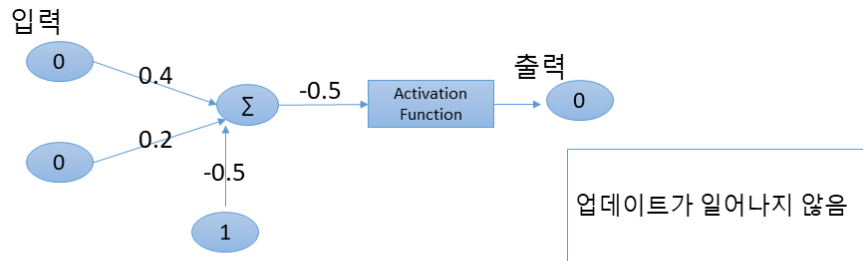


2라운드

| x1 | x2 | d | y |
|----|----|---|---|
| 0  | 0  | 0 | 1 |
| 0  | 1  | 0 | 0 |
| 1  | 0  | 0 | 0 |
| 1  | 1  | 1 | 1 |

2라운드 결과

# And 게이트 학습





3라운드

# 학습된 모델 구현

```
def AND_gate(x1, x2):  
    w1 = 0.4  
    w2 = 0.2  
    # w3은 b로 표시.  
    # b는 1이므로  $1 * w3 = w3$  와 같다. 그러나! 다른 웨이트와 구별하기 위해  
    b = -0.5  
  
    w_sum = w1 * x1 + w2 * x2 + b  
  
    # activation function  
    # 0이하 0, 그 외 1  
    if w_sum <= 0:  
        return 0  
    else:  
        return 1  
  
if __name__ == "__main__":  
    print("(0, 0)", AND_gate(0, 0))  
    print("(0, 1)", AND_gate(0, 1))  
    print("(1, 0)", AND_gate(1, 0))  
    print("(1, 1)", AND_gate(1, 1))
```

# XOR 문제

- ◆ 단층 신경망으로는 XOR 문제를 해결 X
- ◆ 다층 신경망으로 발전 (10년 걸림...)
  - Multi Layer Perceptron; MLP



# 딥러닝 환경 구축시 고려 사항

## ◆ IDE

- Jupyter Lab / notebook
- Visual Studio / VS code
- PyCharm
- Eclipse



Visual Studio Code



한국폴리텍대학  
대구캠퍼스



# 딥러닝 프레임워크

## ◆ TensorFlow (텐서 플로우)

- 구글, 2015년, 가장 널리 사용
- 개방성, 다양한 언어 지원, 많은 사용자
- Python, C/C++ 등 지원
- 초기에 리눅스와 맥OS 만 지원, 현재 윈도우도 지원
- <https://www.tensorflow.org/?hl=ko>

## ◆ Keras (케라스)

- 구글, 2015년, (2017년부터 TensorFlow에서 지원)
- 래퍼 라이브러리(MXNet, DL4J, TensorFlow, CNTK, Theano), Python 기반
- 사용성 우수(모듈화, 최소주의, 확장성)
- <https://keras.io/>, <https://keras.io/ko/>



# 딥러닝 프레임워크


## ◆ PyTorch (파이토치)

- 페이스북, 2016년
- 사용성 우수(코드 구현 장벽 낮음, 사용법 쉬움)
- 텐서 플로우에 비하여 사용자층이 작음
- <https://pytorch.org/>

## ◆ Caffe (카페)

- 버클리 대학, 2013년
- C/C++ 기반, Python 인터페이스
- 컴퓨터비전/CNN/음성 특화, 범용성 낮음
- 모델 공유 네트워크 (커뮤니티, Model Zoo)
- <https://caffe.berkeleyvision.org/>

# 딥러닝 프레임워크



2021년


- TensorFlow 가 가장 인기
- Keras, PyTorch 가 유사한 인기

[출처] <https://towardsdatascience.com/top-5-deep-learning-frameworks-to-watch-in-2021-and-why-tensorflow-98d8d6667351>



한국폴리텍대학  
대구캠퍼스

# 학습 과정



[출처] 모두의 딥러닝

# 출력 - One Hot Encoding

## ◆ Target 은 1로 나머지는 0으로

- 분류(Classification) 문제에서 주로 사용

## ◆ MNIST 예

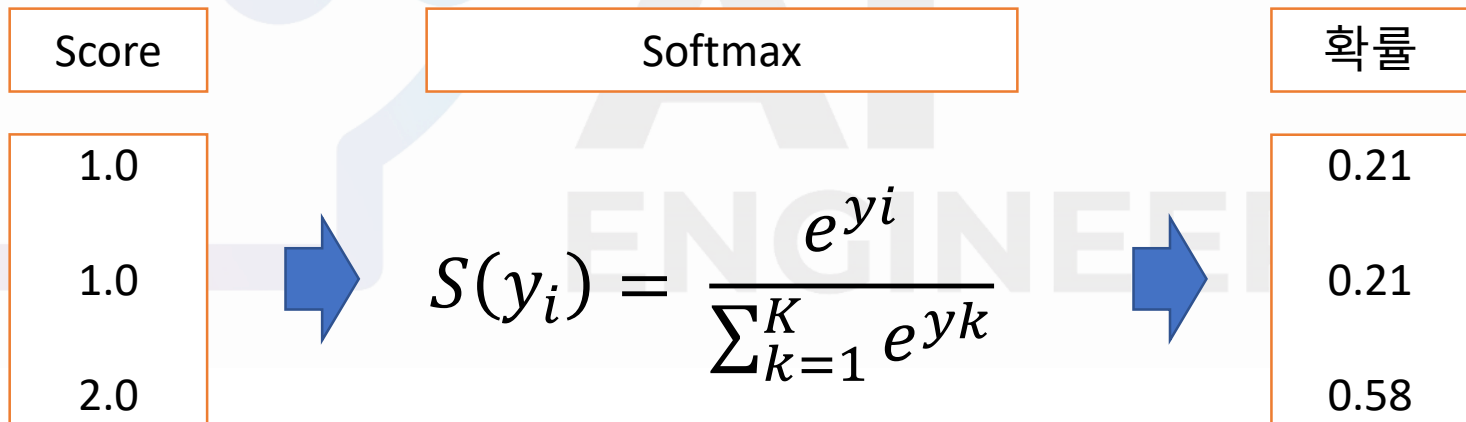
- $1 \rightarrow [0, 1, 0, 0, 0, 0, 0, 0, 0, 0]$
- $5 \rightarrow [0, 0, 0, 0, 0, 1, 0, 0, 0, 0]$
- $9 \rightarrow [0, 0, 0, 0, 0, 0, 0, 0, 0, 1]$

## ◆ 우리 문제

- $0 \rightarrow [1, 0]$
- $1 \rightarrow [0, 1]$

# Softmax

- ◆ 출력값들의 합이 1이 되도록 정규화
- ◆ 확률과 동일한 개념
- ◆ multi class 분류 문제에서 많이 사용



# Softmax

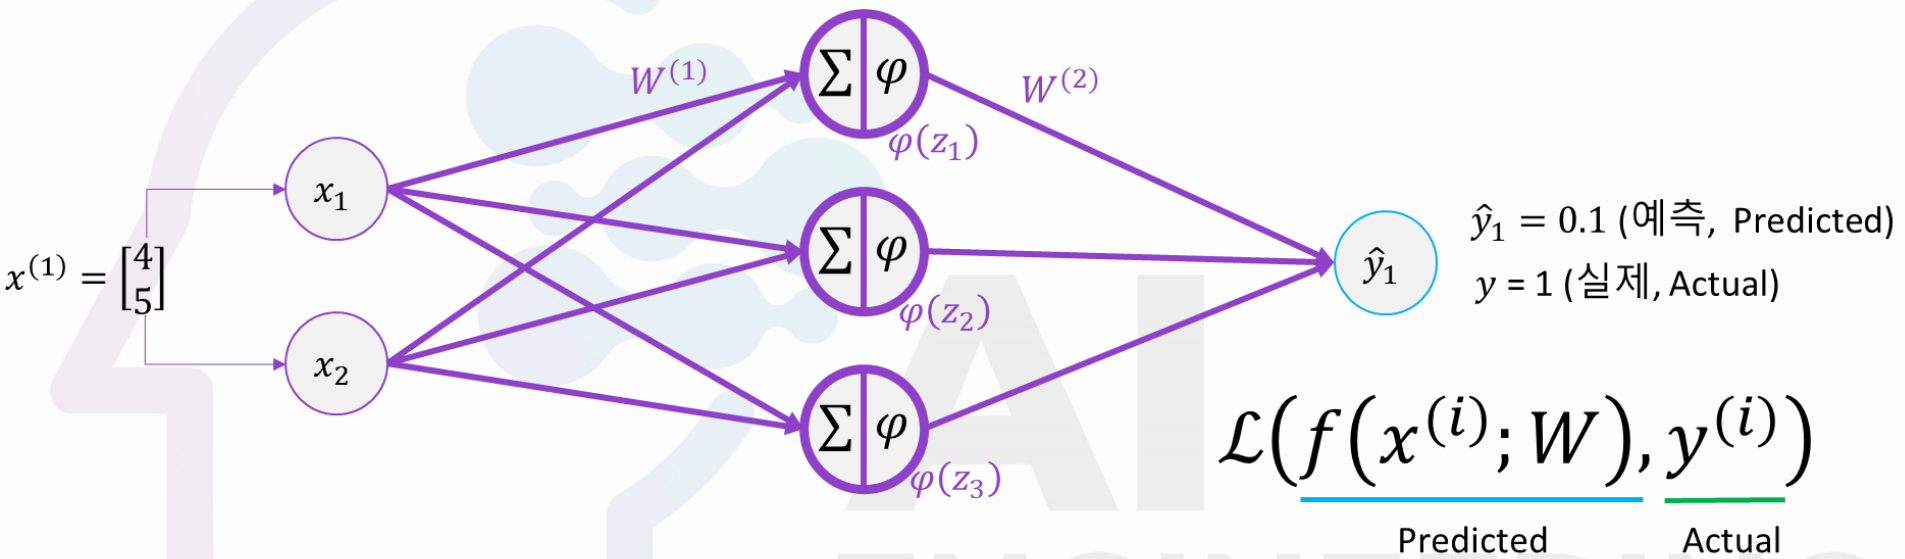
```
def softmax(x):  
    e_x = np.exp(x)  
    sum_e_x = np.sum(e_x)  
    y = e_x / sum_e_x  
  
    return y
```

```
if __name__ == "__main__":  
    a = np.array([1.0, 1.0, 2.0])  
    sm_a = softmax(a)  
    print(sm_a)
```



```
[0.21194156 0.21194156 0.57611688]
```

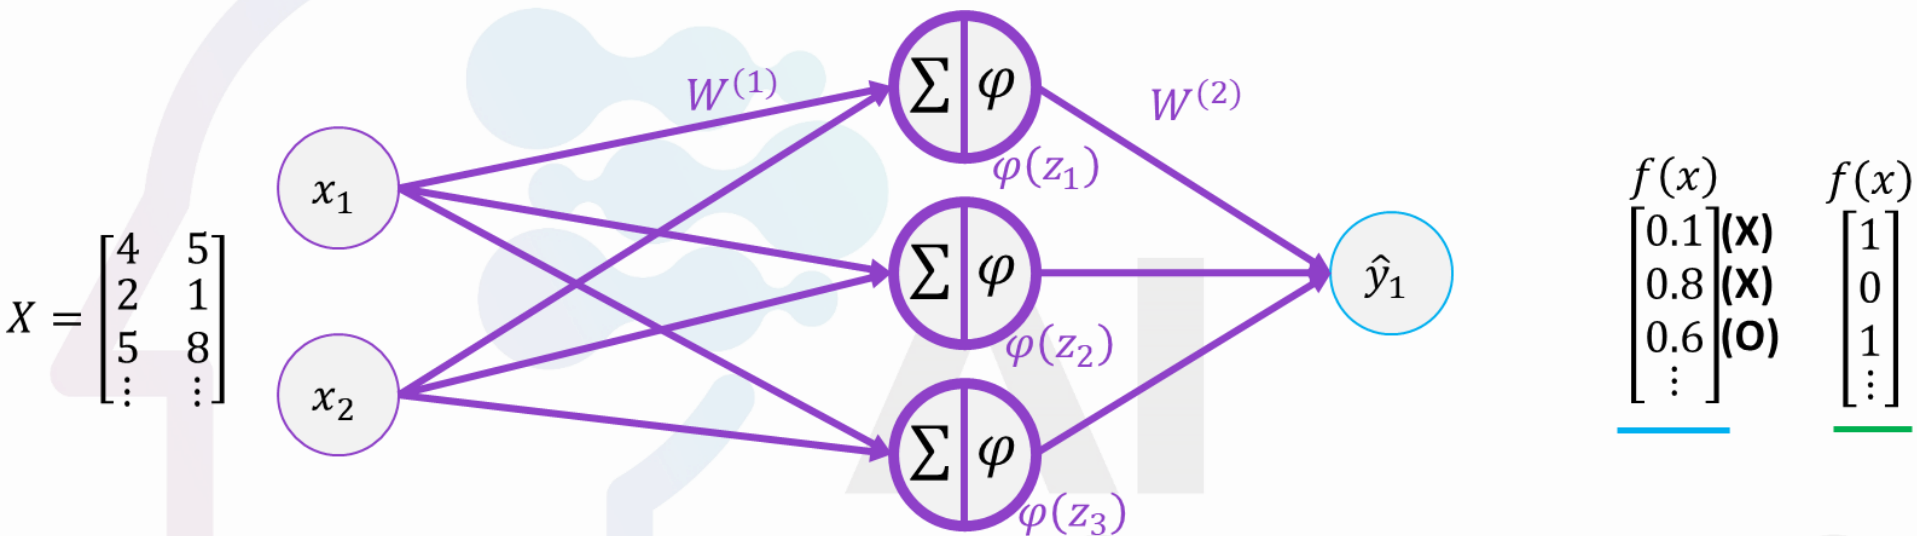
# Loss [손실]





# Empirical Loss


## ◆ 전체 데이터셋에 대한 총 손실을 측정



$$J(W) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f(x^{(i)}; W), y^{(i)})$$

# Mean Squared Error Loss

◆ Regression 문제에서 많이 사용




$$\begin{array}{c} f(x) \\ \begin{bmatrix} 30 \\ 80 \\ 85 \\ \vdots \end{bmatrix} \end{array} \begin{array}{c} (\mathbf{x}) \\ (\mathbf{x}) \\ (\mathbf{o}) \\ \vdots \end{array} \quad \begin{array}{c} f(x) \\ \begin{bmatrix} 90 \\ 20 \\ 95 \\ \vdots \end{bmatrix} \end{array}$$

$$J(W) = -\frac{1}{N} \sum_{i=1}^N \left( y^{(i)} - f(x^{(i)}; W) \right)^2$$

# Binary Cross Entropy Loss

## ◆ 출력이 확률(0~1) 형태일 때 사용



$$\begin{array}{c} f(x) \\ \left[ \begin{array}{c} 0.1 \\ 0.8 \\ 0.6 \\ \vdots \end{array} \right] \begin{array}{l} (\mathbf{x}) \\ (\mathbf{x}) \\ (\mathbf{o}) \end{array} \\ \hline \end{array} \quad \begin{array}{c} f(x) \\ \left[ \begin{array}{c} 1 \\ 0 \\ 1 \\ \vdots \end{array} \right] \end{array}$$

$$J(W) = -\frac{1}{N} \sum_{i=1}^N y^{(i)} \log(f(x^{(i)}; W)) + (1 - y^{(i)}) \log(1 - f(x^{(i)}; W))$$

# 신경망의 학습

## ◆ Loss Optimization

- 손실을 최소화 하는 가중치를 찾는 것

$$W^* = \operatorname{argmin}_W \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f(x^{(i)}; W), y^{(i)})$$

$$W^* = \operatorname{argmin}_W J(W)$$

↑

$$W = \{W^{(1)}, W^{(2)}, \dots\}$$

# Back Propagation

## ◆ 오차 역전파

- MLP 에서 최적화 과정
- 모델의 예측값 과 원하는 값 사이의 오차를 계산
- 경사 하강법을 이용해 오차가 작아지는 방향으로 웨이트를 업데이트

## ◆ 오차가 작아지는 것?

- 미분 값 (기울기)가 0이 되는 방향으로 나아간다

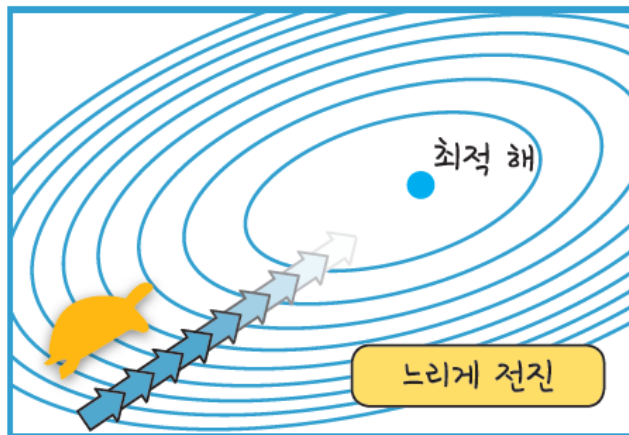
새 가중치는 현 가중치에서 '가중치에 대한 기울기'를 뺀 값

$$W(t+1) = W_t - \frac{\partial \text{오차}}{\partial W}$$

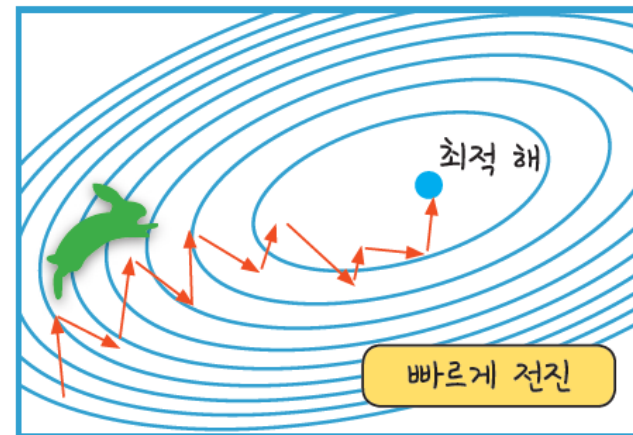
# Loss Optimization

## ◆ Gradient Descent

- 1차 근사값 발견용 최적화 알고리즘
- 함수의 기울기를 구하고 기울기의 절대값이 낮은 쪽으로 계속 이동시켜 극값에 이룰때 까지 반복



경사 하강법



확률적 경사 하강법

$$W \leftarrow W - \eta \frac{\partial J(W)}{\partial W}$$





[출처] 모두의 딥러닝



한국폴리텍대학  
대구캠퍼스

# Loss Optimization

## ◆ 가중치에 따른 손실 분포



# Back Propagation




Image Source  
Joohyoung Jeon

NG

[출처] <https://ds-academy.net/chapter-1-introduction-to-dl/>



한국폴리텍대학  
대구캠퍼스



# Optimization

| 고급 경사 하강법        | 개요  | 효과       | 케라스 사용법  |
|------------------|---|----------|--|
| 확률적 경사 하강법 (SGD) | 랜덤하게 추출한 일부 데이터를 사용해 더 빨리, 자주 업데이트를 하게 하는 것       | 속도 개선    | <code>keras.optimizers.SGD(lr = 0.1)</code><br>케라스 최적화 함수를 이용합니다.  |
| 모멘텀 (Momentum)   | 관성의 방향을 고려해 진동과 폭을 줄이는 효과                         | 정확도 개선   | <code>keras.optimizers.SGD(lr = 0.1, momentum = 0.9)</code><br>모멘텀 계수를 추가합니다.  |
| 네스테로프 모멘텀 (NAG)  | 모멘텀이 이동시킬 방향으로 미리 이동해서 그레디언트를 계산. 불필요한 이동을 줄이는 효과 | 정확도 개선   | <code>keras.optimizers.SGD(lr = 0.1, momentum = 0.9, nesterov = True)</code><br>네스테로프 옵션을 추가합니다.   |
| 아다그라드 (Adagrad)  | 변수의 업데이트가 잦으면 학습률을 적게 하여 이동 보폭을 조절하는 방법           | 보폭 크기 개선 | <code>keras.optimizers.Adagrad(lr = 0.01, epsilon = 1e - 6)</code><br>아다그라드 함수를 사용합니다.<br><br>※ 참고: 여기서 epsilon, rho, decay 같은 파라미터는 바꾸지 않고 그대로 사용하기를 권장하고 있습니다. 따라서 lr, 즉 learning rate(학습률) 값만 적절히 조절하면 됩니다. |

[출처] 모두의 딥러닝



한국폴리텍대학  
대구캠퍼스

# Optimization

| 고급 경사 하강법           | 개요                    | 효과                  | 케라스 사용법   |
|---------------------|-----------------------|---------------------|---|
| 알엠에스프롭<br>(RMSProp) | 아다그라드의 보폭 민감도를 보완한 방법 | 보폭 크기<br>개선         | <code>keras.optimizers.RMSprop(lr = 0.001, rho = 0.9, epsilon = 1e - 08, decay = 0.0)</code><br>알엠에스프롭 함수를 사용합니다.             |
| 아담(Adam)            | 모멘텀과 알엠에스프롭 방법을 합친 방법 | 정확도와<br>보폭 크기<br>개선 | <code>keras.optimizers.Adam(lr = 0.001, beta_1 = 0.9, beta_2 = 0.999, epsilon = 1e - 08, decay = 0.0)</code><br>아담 함수를 사용합니다. |

[출처] 모두의 딥러닝

잘 모르겠으면,  
그냥 Adam 을 사용한다!

# TensorFlow – Keras 로 모델 만들기

```
# keras tensorflow 신경망
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

def make_model():
    model = Sequential()
    model.add(Dense(2, input_dim=2, kernel_initializer='normal', activation="sigmoid"))
    model.summary()
    model.compile(optimizer="adam", loss='binary_crossentropy', metrics=['accuracy'])
    return model
```

Model: "sequential"

| Layer (type)  | Output Shape | Param # |
|---------------|--------------|---------|
| dense (Dense) | (None, 1)    | 3       |

Total params: 3

Trainable params: 3

Non-trainable params: 0



# 학습 해보기

```
if __name__ == "__main__":  
    perceptron_model = make_model()  
  
    x = [[0, 0], [0, 1], [1, 0], [1, 1]]  
    y = [[1, 0], [1, 0], [1, 0], [0, 1]]  
  
    perceptron_model.fit(x, y, epochs=100)  
  
    result = perceptron_model.predict(x)  
    print(result)
```

Epoch 100/100

1/1 [=====] - 0s 0s/step - loss: 0.6457 - accuracy: 1.0000

[[0.54956883 0.4504311 ]

[0.53250307 0.4674969 ]

[0.51435405 0.48564604]


[0.49717474 0.50282526]]

# Multi-layer Perceptron

## ◆ XOR 문제

- 단층 신경망으로는 풀 수 없다
- 새로운 접근이 필요

## ◆ 성냥개비 6개로 정삼각형 3개를 만들어보라




[출처] 모두의 딥러닝

# Multi Layer Perceptron


## ◆ 2차원 평면 노노

➤ 3차원에서는 쉽게 해결



[출처] 모두의 딥러닝


## ◆ XOR 문제의 해결은 평면을 휘어 주는 것



# Multi Layer Perceptron


## ◆ 좌표 평면 자체에 변화

- 2개의 perceptron을 한 번에 계산할 수 있어야 함
- 은닉층 (Hidden layer)를 추가!



# Multi Layer Perceptron


## ◆ 은닉층이 좌표 평면을 왜곡 시키는 결과



<http://colah.github.io/posts/2015-09-NN-Types-FP/>



# MLP 구조



[출처] 모두의 딥러닝

$$n_1 = w_{11}x_1 + w_{21}x_2 + b_1$$

$$n_2 = w_{12}x_1 + w_{22}x_2 + b_2$$




$$W1 = \begin{bmatrix} w_{11} & w_{21} \\ w_{12} & w_{22} \end{bmatrix} \quad X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$B1 = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$



$$N1 = W_1X + B1$$

# MLP 구조



$$y_{out} = w_{31}n_1 + w_{32}n_2 + b_3$$



$$W2 = \begin{bmatrix} w_{31} \\ w_{32} \end{bmatrix} \quad N = \begin{bmatrix} n_1 \\ n_2 \end{bmatrix}$$

$$B2 = [b_3]$$



$$y_{out} = W_2^T N + B2$$

[출처] 모두의 딥러닝

# XOR 문제 풀기

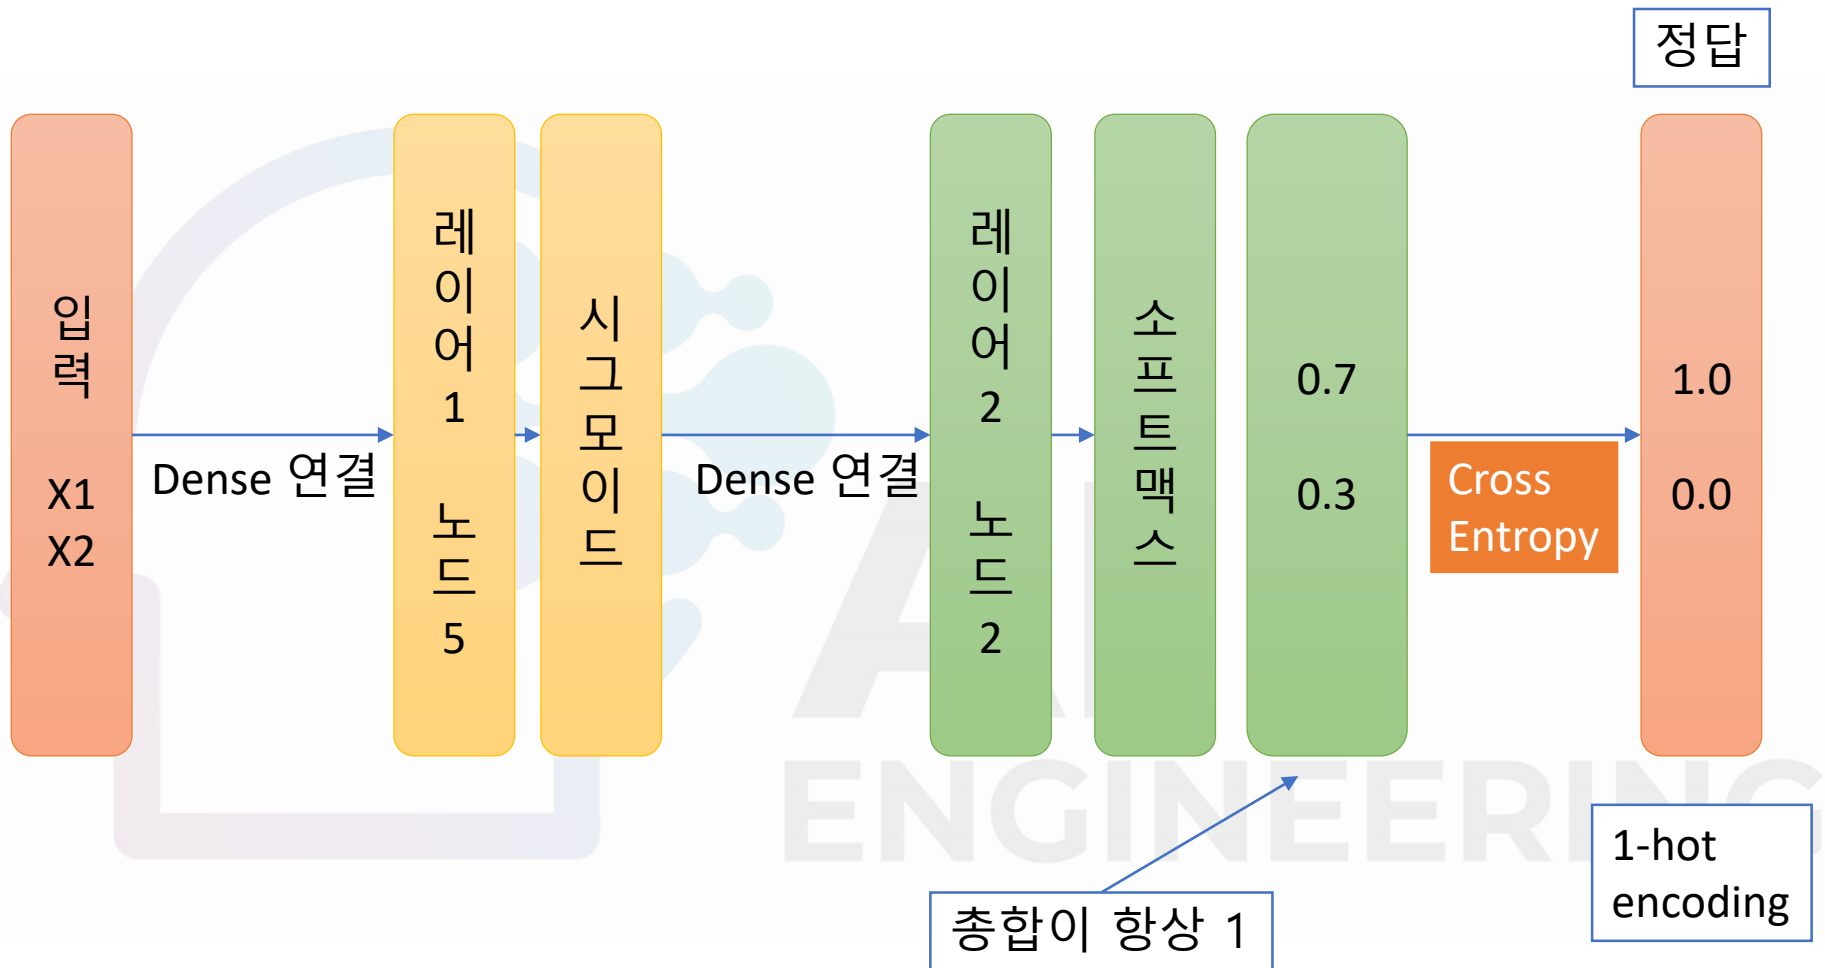
## ◆ 은닉층에 노드 5개 추가

- 적절한 개수? → 실험적으로 찾는다.
- 일반적으로 히든 노드의 개수를 늘이면 학습 잘 됨

## ◆ 출력은 One-hot Encoding으로

- XOR 게이트의 출력 0과 1을 각각의 클래스로 간주
- $[1, 0]$ ,  $[0, 1]$ ,  $[0, 1]$ ,  $[1, 0]$

# 모델 설계



# 모델 구현

```
def make_model():
    model = Sequential()
    model.add(Dense(5, input_dim=2, kernel_initializer='normal',
activation="sigmoid"))
    model.add(Dense(2, input_dim=5, kernel_initializer='normal',
activation="softmax"))
    model.summary()
    model.compile(optimizer="adam", loss="categorical_crossentropy",
metrics=['accuracy'])
    return model
```

| Layer (type)            | Output Shape | Param # |
|-------------------------|--------------|---------|
| =====                   | =====        | =====   |
| dense (Dense)           | (None, 5)    | 15      |
| =====                   | =====        | =====   |
| dense_1 (Dense)         | (None, 2)    | 12      |
| =====                   | =====        | =====   |
| Total params: 27        |              |         |
| Trainable params: 27    |              |         |
| Non-trainable params: 0 |              |         |

# 모델 학습 및 테스트

```
if __name__ == "__main__":  
    perceptron_model = make_model()  
  
    x = [[0, 0], [0, 1], [1, 0], [1, 1]]  
    y = [[1, 0], [0, 1], [0, 1], [1, 0]]  
  
    perceptron_model.fit(x, y, epochs=1000)  
  
    result = perceptron_model.predict(x)  
    print(result)
```

Epoch 1000/1000

1/1 [=====] - 0s 0s/step - loss: 0.3597 - accuracy: 1.0000

[[0.6848706 0.3151294 ]

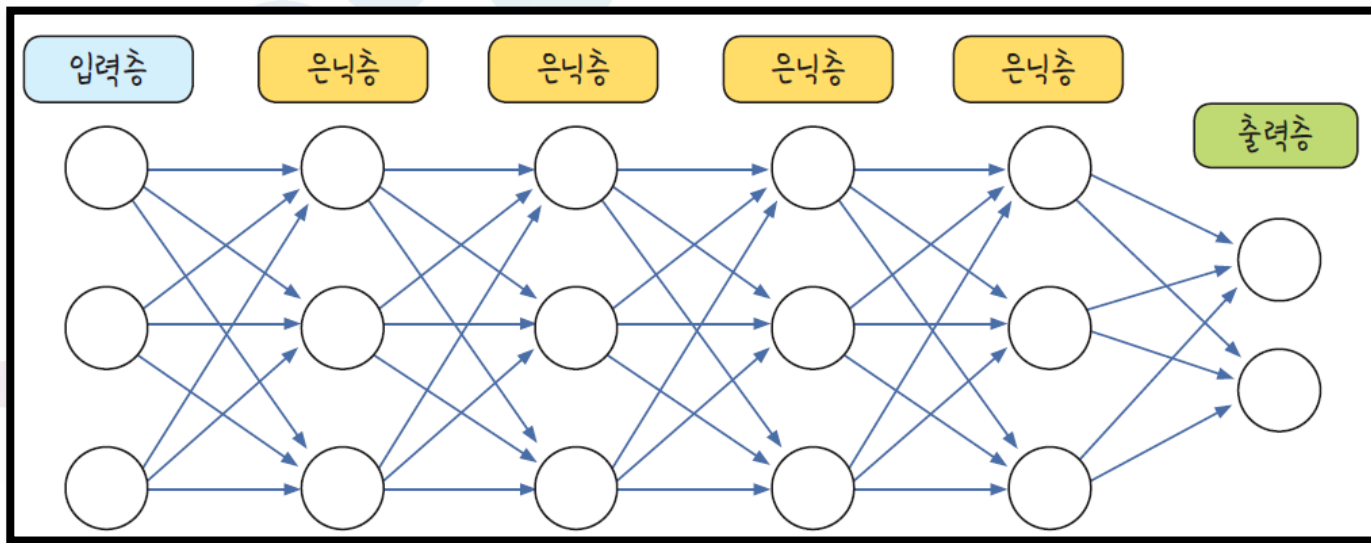
[0.2230476 0.77695245]

[0.380831 0.619169 ]

[0.7218615 0.27813852]]

# Deep Learning

- ◆ MLP 는 XOR 문제를 가볍게 해결
- ◆ 신경망을 차곡 차곡 쌓기만 하면 되겠네?  
➤ ~~응 아니야.~~

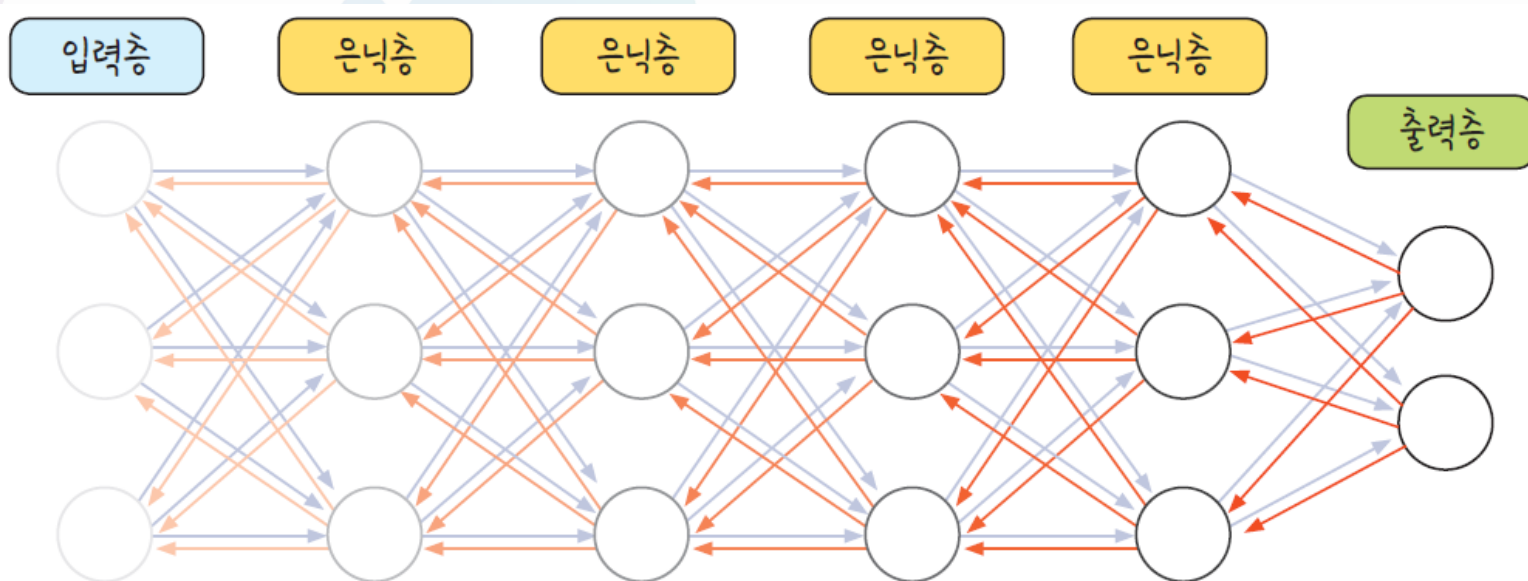


[출처] 모두의 딥러닝

# Gradient Vanishing

## ◆ Back Propagation

- 출력층으로 되돌아가며 가중치를 수정
- 이 때 미분을 사용하는데...




[출처] 모두의 딥러닝



# Gradient Vanishing

## ◆ Sigmoid 함수를 미분하면




- 여러 층을 거칠 수록 기울기가 사라짐
- 가중치를 수정할 수 없게 됨

[출처] 모두의 딥러닝

# Activation Function

## ◆ 활성화 함수를 다른 걸 써야겠구나?!



[출처] 모두의 딥러닝

# Activation Function


## ◆ Keras 는 다양한 활성화 함수를 지원

- <https://keras.io/ko/activations/>
- <https://subinium.github.io/introduction-to-activation/>

Rectified Linear Unit

제프리 힌튼

시그모이드의 대안으로 떠오르며,  
현재 가장 널리 사용



# Summary

## ◆ 신경망이란?

- 인간의 뉴런을 모방
- Activation Function

## ◆ 학습이란?

- 손실이 최소가 되는 최적의 Weight를 찾는 것
- 오류 역전파를 통해 손실을 앞으로 전달

## ◆ 다음 시간?

- MNIST 손글씨 인식
- Cifar-10 이미지 분류 실습