Al+x 인재양성 확대를 위한 교수자 연수

한국폴리텍대학 대구캠퍼스 AI엔지니어링학과 강현우

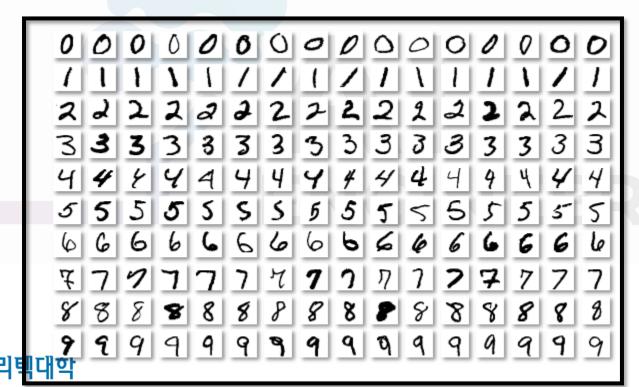
- 4강 MNIST 손글씨

-MNIST 손 글씨 데이터를 분류해본다



MNIST

- ◆MNIST 데이터베이스
 - ➤ NIST 미국 국립표준기술 연구소
 - National Institute of Standards and Technology
 - > Modified NIST 데이터 베이스



MNIST Data

- ◆ 손 글씨로 쓰여진 숫자 데이터
 - ▶클래스 10개
- ◆ 데이터 셋 구성
 - >트레이닝 데이터 60000개
 - >테스트 데이터 10000개
- ◆ 적절한 난이도… 기계 학습 하기에 적당하다.



Data load

- ◆ Github 에서 다운로드 가능
 - https://github.com/Al-Engineering/Al-X-2021.7/tree/main/src/mnist/dataset

```
def load_dataset(online=False):
  if online:
     (tr_data, tr_label), (te_data, te_label) = tf.keras.datasets.mnist.load_data()
  else:
     path = "D:/Project/Mnist/dataset/mnist.npz"
     (tr_data, tr_label), (te_data, te_label) = tf.keras.datasets.mnist.load_data(path)
  print("학습 데이터 {0}개 로드".format(tr_data.shape[0]))
  print("테스트 데이터 {0}개 로드".format(te_data.shape[0]))
  return (tr_data, tr_label), (te_data, te_label)
     한국퐄리텍대학
```

Data 확인

```
(train_set, train_label), (test_set, test_label) = load_dataset()

print(train_set.shape) 28x28 인 2차원 배열이 6만개
print(train_label.shape)
print(train_label[0].shape)
print(test_set.shape) 28x28 인 2차원 배열이 6만개
print(test_label.shape) 1만개
```

```
(60000, 28, 28)
(28, 28)
(60000,)
()
(10000, 28, 28)
(10000,)
```



Data 확인

- ◆ 학습 데이터
 - > 28x28 사이즈의 이미지
 - → 각 픽셀의 값은 0 ~ 255
- ◆ 정답 데이터
 - > 0 ~ 9 사이의 숫자

print(train_set[0])
print(train_label[:100])



Data 확인

```
oxed{0} 
      0 0 0 0 0 0 0 0 0 0 0 3 18 18 18 126 136 175 26 166 255 247 127 0 0 0 0
      0 0 0 0 0 0 0 30 36 94 154 170 253 253 253 253 253 225 172 253 242 195 64 0 0 0 0
      0 0 0 0 0 49 238 253 253 253 253 253 253 253 251 93 82 82 56 39 0 0 0 0 0
[ 0 0 0 0 0 0 0 18 219 253 253 253 253 198 182 247 241 0 0 0 0 0 0 0 0 0 0 0
[ 0 0 0 0 0 0 0 0 80 156 107 253 253 205 11 0 43 154 0 0 0 0 0 0 0 0 0 0 0
[0 0 0 0 0 0 0 0 0 14 1 154 253 90 0 0 0 0 0 0 0 0 0 0 0 0 0 0
[0 0 0 0 0 0 0 0 0 0 0 139 253 190 2 0 0 0 0 0 0 0 0 0 0 0 0 0 0
[ 0 0 0 0 0 0 0 0 0 0 0 0 0 35 241 225 160 108 1 0 0 0 0 0 0 0 0 0 0 0 0
[ 0 0 0 0 0 0 0 0 0 0 0 0 0 0 81 240 253 253 119 25 0 0 0 0 0 0 0 0 0 0
      0 0 0 0 0 0 0 0 0 0 0 0 0 45 186 253 253 150 27 0 0 0 0 0 0 0 0
      0 0 0 0 0 0 0 0 0 0 0 0 0 0 16 93 252 253 187 0 0 0 0 0 0 0 0
      0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 249 253 249 64 0 0 0 0 0 0 0]
      0 0 0 0 0 0 0 0 0 0 0 0 0 0 46 130 183 253 253 207 2 0 0 0 0 0 0 0
      0 0 0 0 0 0 0 0 0 0 0 39 148 229 253 253 250 182 0 0 0 0 0 0 0 0
[ 0 0 0 0 0 0 0 0 0 0 0 24 114 221 253 253 253 201 78 0 0 0 0 0 0 0 0 0 0
[ 0 0 0 0 0 0 0 0 23 66 213 253 253 253 198 81 2 0 0 0 0 0 0 0 0 0 0 0 0
[ 0 0 0 0 0 0 18 171 219 253 253 253 253 195 80 9 0 0 0 0 0 0 0 0 0 0 0 0 0
      0 0 0 55 172 226 253 253 253 253 244 133 11 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
      0 0 0 136 253 253 253 212 135 132 16 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
```

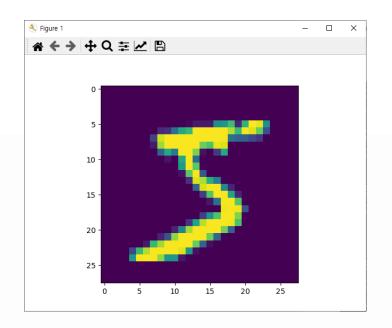
무엇 처럼 보이는가?!


픽셀의 밝기 값을 0~255 사이로 표현



Image Show

```
# 이미지로 보고 싶을 때
def show_image(index):
  plt.imshow(train_set[index])
  plt.show()
userInput = ""
data_num = 0
while userInput != "q":
  show_image(data_num)
  data_num += 1
  userInput = input("next: ")
```









살짝 데코레이션

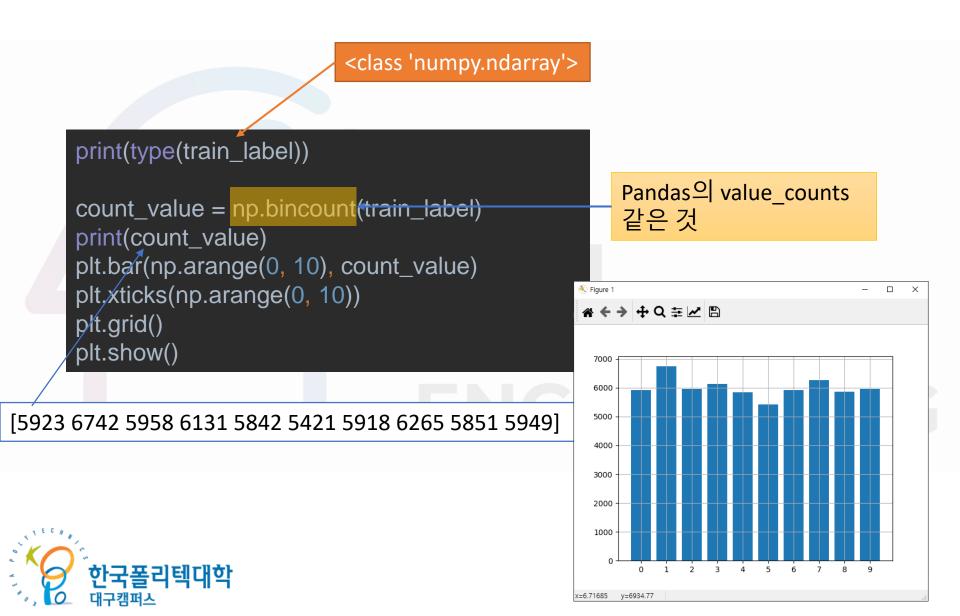
◆ 글자가 검정인 편이 익숙하니까? ㅎ_ㅎ

plt.imshow(255-train_set[index], cmap="gray")





데이터 분포



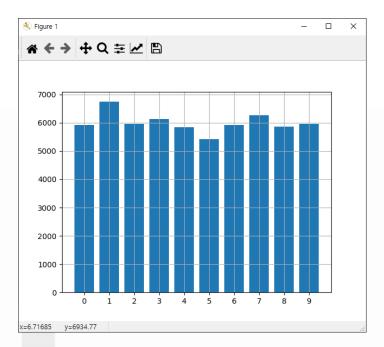
데이터 분포

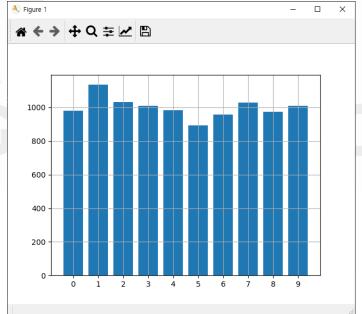
```
def show_data_values(label):
    count_value = np.bincount(label)
    print(count_value)
    plt.bar(np.arange(0, 10), count_value)
    plt.xticks(np.arange(0, 10))
    plt.grid()
    plt.show()
```

```
# 메인

if __name__ == "__main__":
    (train_set, train_label), (test_set,
test_label) = load_dataset()

show_data_values(train_label)
show_data_values(test_label)
```







데이터 변환

- ◆ 차원 변환
 - > 2차원 [28 x 28] → 1차원 784로
 - > 0 ~ 255 uint → 0~1 float 으로

```
# 데이터 변환
train_set = train_set.reshape(60000, 784)
train_set = train_set.astype("float32")
train_set /= 255

# 짧게 쓰면 이렇게...
test_set = test_set.reshape(10000, 784).astype("float32") / 255
```



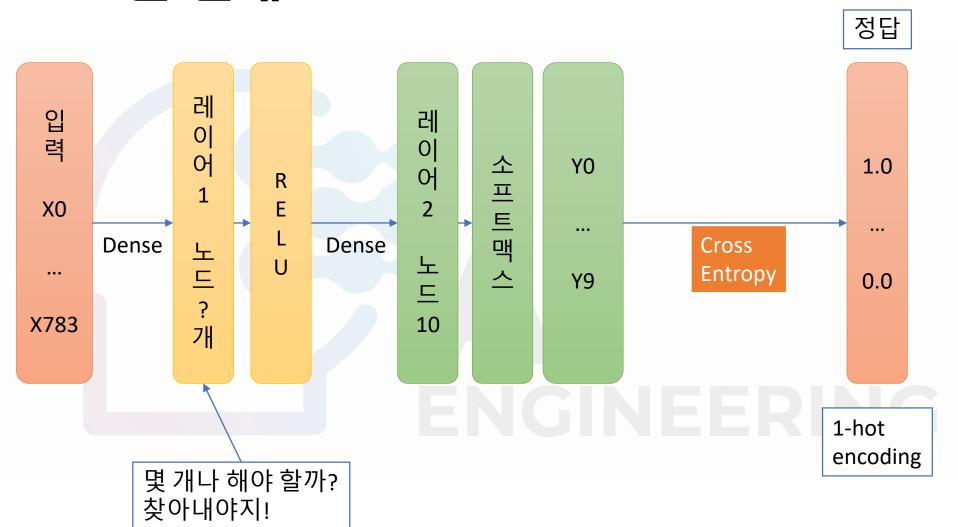
One-Hot Encoding

- ◆ 정답만 1로 나머지는 0으로..
 - $> 1 \rightarrow [0, 1, 0, 0, 0, 0, 0, 0, 0, 0]$
 - > 5 \rightarrow [0, 0, 0, 0, 0, 1, 0, 0, 0, 0]

```
# 정답은 one-hot encoding
train_label = tf.keras.utils.to_categorical(train_label, 10)
test_label = tf.keras.utils.to_categorical(test_label, 10)
print(train_label[0])
```



모델 설계



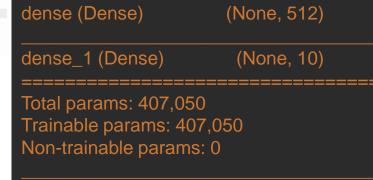


모델 구현

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
def make_model():
  model = Sequential()
  model.add(Dense(512, input_dim=784, activation="relu"))
  model.add(Dense(10, activation="softmax"))
  model.summary()
  model.compile(loss="categorical_crossentropy",
          optimizer="adam",
           metrics=["accuracy"])
```

return model

40만 7천개	정도야	훗
---------	-----	---



Layer (type)

Output Shape

Param #

401920

5130



학습과 저장

```
# 하이퍼 파라메터
MY_EPOCH = 30
MY_BATCHSIZE = 200

def train(model, x, y):
    history = model.fit(x, y, epochs=MY_EPOCH, batch_size=MY_BATCHSIZE)
    model.save("./model/mlp_hd512.h5")
    return history
```

```
# 모델 생성
mlp = make_model()

# 학습
train(mlp, train_set, train_label)
```

테스트

```
# 저장된 모델로 테스트 하기 테스트
from tensorflow.keras.models import load_model
mlp = load_model("./model/mlp_hd512.h5")
acc = mlp.evaluate(test_set, test_label, batch_size=MY_BATCHSIZE)
print(acc)
```

accuracy: 0.9833

[0.07162203639745712, 0.983299970626831]



심화 실습

◆ 모델의 예측 값과 정답 레이블을 비교하여 Confusion Matrix 를 생성 하시오.

